

Noções Iniciais de Análise de Sobrevivência e o Método de Kaplan-Meier

Núbia Karla de Oliveira Almeida e Pedro Frazão Dutra
Universidade Federal Fluminense

Introdução

Análise de Sobrevivência é uma técnica estatística usualmente utilizada na área médica para investigar fatores que possam vir a influenciar a sobrevida de pacientes com uma certa doença [1, 2, 3]. Tais fatores em geral são referentes a características socioeconômicas dos pacientes, da doença e do tratamento. Apesar de amplamente adotada como metodologia de pesquisa na área de saúde, a Análise de Sobrevivência também pode ser utilizada em outros ramos. Em engenharia, por exemplo, a técnica é conhecida como Análise de Confiabilidade, cujo interesse na maioria das vezes é investigar fatores que afetam o tempo de vida de um equipamento, tais como materiais e componentes [5]. Já na área de economia poderia se pensar no tempo decorrido entre a emissão do cartão de crédito e a 1ª vez que o cliente ficou inadimplente das despesas realizadas com o cartão [4]. Algumas variáveis que poderiam afetar o tempo até a inadimplência e que, portanto, deveriam ser investigadas seriam, idade, composição familiar, renda familiar, dentre outras. Sendo assim, não é difícil perceber que Análise de Sobrevivência é uma técnica com aplicação em áreas diversas.

Conceitos Gerais

Em Análise de Sobrevivência, o objetivo principal é identificar características que influenciam o tempo decorrido entre o início da observação do objeto de interesse do estudo e a ocorrência de um evento denominado *falha*. Na área da saúde, a falha, em geral, é o óbito do paciente, mas pode ser também a calcificação de um osso após uma fratura. Assim, o termo falha não deve ser necessariamente associado a um evento negativo, mas sim ao evento que se deseja investigar. No entanto, nem sempre é observado o tempo até a falha do objeto de estudo (paciente, equipamento, conta bancária, ...). Nesses casos, diz-se que ocorre o evento denominado *censura*.

Para formalizar alguns conceitos de Análise de Sobrevivência, é necessário ter clareza sobre algumas

definições [1, 2, 3], a saber:

T: variável aleatória que denota o tempo decorrido entre o início do acompanhamento de um elemento/indivíduo na pesquisa e a ocorrência da falha;

falha: evento de interesse no estudo;

censura: evento que indica a não observação do tempo até a falha.

As censuras podem ser classificadas como à esquerda, intervalar e à direita [2], sendo esta última a mais comum. Na censura à direita, há perda da informação sobre o tempo decorrido até a falha, seja porque o indivíduo sob acompanhamento decidiu não participar mais do estudo, seja porque saiu do estudo devido a uma causa não relacionada com a falha, ou ainda porque o estudo se encerrou e a falha não havia ocorrido. Entretanto, existem censuras relacionadas à falha, como, por exemplo, quando ocorre o agravamento do estado de saúde de um paciente e há a necessidade de transferência de hospital. Nesse caso, o hospital perde a informação do paciente que estava sob acompanhamento, mas o tempo de sua permanência no estudo não deve ser ignorado. Situações como essa demandam o uso de técnicas mais complexas de Análise de Sobrevivência [1, 2, 3].

Em pesquisas que envolvem Análise de Sobrevivência, também é usual que os desenhos dos estudos considerem coortes abertas, que permitem a entrada de novos participantes na investigação a qualquer momento dentro de uma janela temporal que delimita o início e o fim da pesquisa. A Figura 1 ilustra uma coorte aberta em que há cinco pacientes que apresentam falha e cinco pacientes que são censurados à direita. Observa-se que, considerando a janela temporal da pesquisa de 2010 a 2019, apenas os indivíduos 1, 4 e 7 iniciaram sua participação no estudo desde o início, enquanto os demais indivíduos ingressaram em momentos distintos.




Figura 1: Estudo na escala cronológica.

Para melhor visualização do tempo até falha de cada indivíduo, a Figura 2 exibe os valores em tempo corrido. Assim, comparando as Figuras 1 e 2, percebe-se que o indivíduo 2, que havia entrado no estudo em 2013 e falhado em 2017, contribui na pesquisa com o tempo de falha de 4 anos.




Figura 2: Estudo na escala do tempo corrido.

Metodologia de estimação da função de sobrevivência

Em Análise de Sobrevivência, há mais de uma abordagem para estimar as sobrevidas dos indivíduos envolvidos no estudo [1, 2, 3], e aqui será apresentada brevemente a de Kaplan-Meier. Primeiramente, seja definida a função de sobrevivência (ou de sobrevida) associada ao tempo t , dada por

$$S(t) = P(T > t), \quad t \in \mathbb{R}^+. \quad (1)$$

Portanto, se o tempo estiver sendo medido em anos, $S(10)$ representaria a probabilidade de um indivíduo

sobreviver por mais de 10 anos ou, de forma equivalente, a probabilidade de a falha ocorrer após 10 anos. Teoricamente, a função de sobrevivência apresenta as seguintes características:

$$S(0) = 1 \quad \text{e} \quad \lim_{t \rightarrow \infty} S(t) = 0. \quad (2)$$

Graficamente seu comportamento teórico é exibido na Figura 3.




Figura 3: Curva teórica da função de sobrevivência.

Estimador de Kaplan-Meier

No método de Kaplan-Meier, as estimativas da função de sobrevivência se baseiam exclusivamente nos dados que foram observados ao longo do período da pesquisa [1, 2, 3]. Trata-se da metodologia mais simples em Análise de Sobrevivência, na qual as estimativas da função de sobrevida são obtidas para determinados intervalos de tempo, definidos a partir das falhas observadas. Além disso, este método é conhecido por ser do tipo não paramétrico, uma vez que não faz suposições sobre a distribuição de probabilidade associada à variável aleatória T . Entrando em detalhes sobre este método, sejam:

$$t_1 < t_2 < t_3 < \dots < t_k \quad (3)$$

os k tempos de falha distintos observados na investigação. Considere também as seguintes quantidades:

d_j : nº de falhas ocorridas no tempo t_j ;

c_j : nº de censuras ocorridas no intervalo $[t_j, t_{j+1})$;

n_j : nº de indivíduos em risco de falha no tempo imediatamente anterior a t_j ;

$j = 1, 2, \dots, k$.

No cenário apresentado na Figura 2, não é difícil perceber que existem $k = 5$ tempos de falha distintos (1, 2, 4, 5 e 8). Sendo assim, tem-se, por exemplo, que:

d_1 : n^o de indivíduos que falharam no tempo $t_1 = 1$;

$d_1 = 1 \leftrightarrow$ indivíduo 6;

c_1 : n^o de censuras ocorridas no intervalo $[t_1, t_2) = [1, 2)$;

$c_1 = 1 \leftrightarrow$ indivíduo 8;

n_1 : n^o de indivíduos em risco de falha no tempo imediatamente anterior a $t_1 = 1$;

$n_1 = 10 \leftrightarrow$ todos os indivíduos.

De forma análoga, são obtidos os valores da Tabela 1.

Tabela 1: Números de indivíduos em risco, de falhas e de censuras, por tempo de falha.

j	t_j	n_j	d_j	c_j
1	$t_1 = 1$	10	1	1
2	$t_2 = 2$	8	1	2
3	$t_3 = 4$	5	1	1
4	$t_4 = 5$	3	1	0
5	$t_5 = 8$	2	1	1

Agora, para se estimar a função de sobrevivência no tempo $t_1 = 1$, basta avaliar quantos indivíduos havia em risco e quantos sobreviveram a este tempo, ou seja:

$$P(T > 1) = \frac{n_1 - d_1}{n_1} = \frac{10 - 1}{10} \quad (4)$$

$$\hat{S}(1) = 0,900.$$

Para o tempo $t_2 = 2$, deve-se atentar que, para sobreviver ao tempo 2, é necessário ter sobrevivido primeiramente ao tempo $t_1 = 1$ e não ter sido censurado no intervalo $[t_1, t_2) = [1, 2)$. Em termos de probabilidades, isso pode ser expresso por:

$$P(T > t_2) = P(T > t_1 \cap T > t_2) \quad (5)$$

$$= P(T > t_2 \mid T > t_1) \times P(T > t_1),$$

mas

$$P(T > t_2 \mid T > t_1) = \frac{n_2 - d_2}{n_2} = \frac{8 - 1}{8} \quad (6)$$

$$= 0,875.$$

Portanto,

$$\hat{S}(2) = 0,875 \times 0,90 \approx 0,787. \quad (7)$$

Considerando agora o tempo $t_3 = 4$, faz sentido novamente considerar as seguintes igualdades:

$$P(T > t_3) = P(T > t_1 \cap T > t_2 \cap T > t_3)$$

$$= P(T > t_3 \mid T > t_1 \cap T > t_2)$$

$$\times P(T > t_1 \cap T > t_2) \quad (8)$$

$$= \frac{n_3 - d_3}{n_3} \times 0,787$$

$$= \frac{5 - 1}{5} \times 0,787 = 0,630 = \hat{S}(4).$$

O padrão dos cálculos permite expressar a forma geral do estimador da função de sobrevivência, via método de Kaplan–Meier, por:

$$\hat{S}(t) = \prod_{j|t_j \leq t} \frac{n_j - d_j}{n_j}. \quad (9)$$

No exemplo que está sendo considerado, seriam obtidos os valores apresentados na Tabela 2 e a respectiva curva da função de sobrevivência teria o comportamento exibido na Figura 4.

Tabela 2: Estimativas para a função de sobrevivência por tempo de falha.

j	$t \in [t_j, t_{j+1})$	$\hat{S}(t)$
–	$[0, 1)$	1,000
1	$[1, 2)$	0,900
2	$[2, 4)$	0,787
3	$[4, 5)$	0,630
4	$[5, 8)$	0,420
5	$[8, \infty)$	0,210




Figura 4: Curva estimada da função de sobrevivência – Kaplan-Meier.

Observa-se claramente que a curva em formato escada (Figura 4) contém pontos de descontinuidade, dife-

rentemente da teórica (Figura 3), mas caso o número de indivíduos na pesquisa fosse maior, mais valores distintos de tempos de falha tenderiam a ocorrer, suavizando a curva de sobrevivência.

Estimador de Kaplan-Meier por estratos

O método de Kaplan-Meier também permite que sejam obtidas estimativas para subgrupos de participantes da pesquisa [1, 2]. Em geral, consideram-se estratos das variáveis qualitativas contempladas na investigação. Assim, em um estudo que se investiga a sobrevivência de pacientes com uma certa doença crônica, sendo a falha definida como o óbito do paciente, seria possível estimar as funções de sobrevivência, por exemplo, de acordo com os estratos da faixa etária do paciente (jovens/adultos/idosos), estágio da doença no momento do diagnóstico (inicial/intermediário/avançado) e tipo de tratamento (A/B), dentre outros. O procedimento metodológico seria o mesmo, mas considerando cada estrato separadamente. Em termos de representação gráfica, as curvas de cada estrato são usualmente exibidas em uma mesma figura. Por exemplo, caso os indivíduos 1, 2, 5, 7 e 9 tivessem sido submetidos ao tratamento A e os demais ao tratamento B, as curvas das funções de sobrevivência de cada tratamento estariam de acordo com o que é ilustrado na Figura 5. O comportamento das curvas sugere que há maior risco de óbito para aqueles que se submetem ao tratamento B, uma vez que se identifica, dentre outros aspectos, que $\hat{S}(2)$ vale 1,00 e 0,533, respectivamente para os tratamentos A e B.




Figura 5: Curva estimada da função de sobrevivência por estratos – Kaplan-Meier.

A interpretação gráfica das curvas de sobrevivência referentes aos estratos de uma variável, por ter um cu-

nho pessoal e subjetivo, pode algumas vezes induzir a conclusão sobre diferenças das funções de sobrevivência, que de fato não existem. Assim, há de se considerar um teste estatístico que averigue a igualdade ou não nas sobrevivências associadas a cada um dos estratos. O teste Log-Rank viabiliza esta avaliação.

Teste Log-Rank

O teste Log-Rank, em sua essência, verifica se as frequências observadas de falhas nos r estratos ao longo dos tempos t_j ($j = 1, 2, \dots, k$) são estatisticamente iguais (ou não) as frequências esperadas de falhas, considerando que os estratos tenham funções de sobrevivência idênticas. Assim, as hipóteses envolvidas no teste são [1, 2, 3]:

$$H_0 : S_1(t) = S_2(t) = \dots = S_r(t),$$

$$H_1 : \exists u, v \mid S_u(t) \neq S_v(t),$$

sendo r o número de estratos da variável em análise.

Para cada tempo de falha t_j é construída uma tabela com informações sobre o número de indivíduos em risco e de falhas em cada estrato, conforme exibido na Tabela 3.

Tabela 3: Números de indivíduos em risco e de falhas, por estrato.

Estrato	nº em risco	nº de falhas
1	n_{1j}	d_{1j}
2	n_{2j}	d_{2j}
$\vdots$	$\vdots$	$\vdots$
r	n_{rj}	d_{rj}
Total	n_j	d_j

Assim, a proporção de falhas em cada estrato, no tempo t_j , é dada por:

$$\frac{d_{ij}}{n_{ij}}, \quad i = 1, \dots, r \quad \text{e} \quad j = 1, \dots, k. \quad (10)$$

Nota-se que, uma vez fixado o tempo t_j e dada a hipótese nula, as proporções de falha em cada estrato deveriam ser bem parecidas. Isso significaria que a ocorrência da falha não estaria associada aos estratos da variável investigada e, dessa forma, a proporção de falhas no tempo t_j poderia ser estimada diretamente por:

$$\frac{d_j}{n_j}, \quad j = 1, \dots, k. \quad (11)$$

Uma vez obtida essa estimativa, esperar-se-ia que o número de falhas no estrato i ($i = 1, 2, \dots, r$) fosse:

$$e_{ij} = n_{ij} \times \frac{d_j}{n_j}, \quad j = 1, \dots, k. \quad (12)$$

Portanto, o vetor de desvios no tempo t_j seria dado por:

$$\mathbf{w}_j = \begin{pmatrix} d_{1j} - e_{1j} \\ d_{2j} - e_{2j} \\ \vdots \\ d_{rj} - e_{rj} \end{pmatrix}, \quad (13)$$

e o vetor de desvios ao longo de todos os tempos de falha, dado por:

$$\mathbf{w} = \sum_{j=1}^k \mathbf{w}_j = \begin{pmatrix} \sum_{j=1}^k (d_{1j} - e_{1j}) \\ \sum_{j=1}^k (d_{2j} - e_{2j}) \\ \vdots \\ \sum_{j=1}^k (d_{rj} - e_{rj}) \end{pmatrix}. \quad (14)$$

A estatística de teste a ser utilizada teria a seguinte expressão [3]:

$$\mathbf{w}' \mathbf{W}^{-1} \mathbf{w}, \quad (15)$$

sendo

$$\mathbf{W} = \sum_j \mathbf{W}_j, \quad (16)$$

com $\mathbf{W}_j$ denotando a matriz variância-covariância (de dimensão $r \times r$) da quantidade de falhas dos estratos no tempo t_j . Além disso, a estatística de teste,

à medida que o tamanho da amostra de elementos no estudo aumenta, tende a ter uma distribuição χ^2 com $r - 1$ graus de liberdade [3]. Com base nessa distribuição, é viável calcular o p -valor associado ao teste e inferir se a hipótese nula de igualdade das funções de sobrevivência será rejeitada ou não.

Agradecimento

Os autores agradecem à Fundação de Amparo à Pesquisa do Estado do Rio de Janeiro (FAPERJ) pelo apoio financeiro concedido por meio de projeto de Iniciação Científica (Edital FAPERJ Nº 23/2024).

Referências

- [1] COLOSIMO, E.A.; GIOLO, S. “Análise de Sobrevivência Aplicada”. *Blucher*, São Paulo, 367p, ISBN 85-212-0384-5, 2006.
- [2] CARVALHO, M.S. et al. “Análise de Sobrevivência: Teoria e Aplicações em Saúde”. *Fiocruz*, 2ª edição (revista e ampliada), ISBN: 978-85-7541-216-9, 2011.
- [3] KALBFLEISCH, J.D.; PRENTICE, R.L. “The Statistical Analysis of Failure Time Data”. *Hoboken: John Wiley & Sons*, 2ª edição, 2002.
- [4] LANCASTER, J.J. “The econometric analysis of transition data”. *Cambridge: Cambridge University Press*, 1990.
- [5] MEEKER, W.Q.; ESCOBAR, L. A.; PASQUAL, F. G. “Statistical methods for reliability data”. *Hoboken: Wiley*, 2021.