

Universidade Federal Fluminense

**Análise de Sobrevivência de Mulheres em Tratamento de
Câncer de Mama - Abordagem Não-Paramétrica**

Autor: Pedro Frazão Dutra

Orientadora: Núbia Karla de Oliveira Almeida

Niterói - RJ, Brasil

Janeiro 2026

Sumário

1	Introdução	p. 3
2	Desenvolvimento do trabalho	p. 4
2.1	Estudo dirigido	p. 4
2.1.1	Definições básicas	p. 4
2.1.2	Método de Kaplan-Meier	p. 6
2.1.3	Teste Log-Rank	p. 9
2.1.4	Tempo mediano de sobrevivência	p. 11
2.1.5	Intervalos de confiança para valores da função de sobrevida . . .	p. 11
2.2	Revisão bibliográfica	p. 14
2.3	Acesso e análise preliminar dos dados	p. 17
2.4	Estimação das funções de sobrevivência e teste Log-Rank	p. 20
3	Resultados	p. 21
3.1	Análises estatísticas	p. 21
3.2	Divulgação dos resultados	p. 29
4	Conclusão	p. 31
	Referências	p. 33

1 Introdução

Análise de Sobrevivência é uma técnica estatística usualmente utilizada na área da saúde para investigar fatores que possam vir a influenciar a sobrevida de pacientes com uma certa doença [1, 2, 3]. Tais fatores em geral são referentes a características socioeconômicas dos pacientes, da doença e do tratamento. A técnica, no entanto, poderia ser adotada também para avaliar a dose cumulativa de quimioterapia até a toxicidade grave ou mesmo a quantidade total administrada de um antibiótico até a 1ª evidência de redução da carga bacteriana. Apesar de amplamente utilizada como metodologia de pesquisa em ciências da saúde, a Análise de Sobrevivência também pode ser aplicada em outros ramos. Em engenharia, por exemplo, a técnica é conhecida como Análise de Confiabilidade, cujo interesse na maioria das vezes é investigar fatores que afetam o tempo de vida de um equipamento, tais como materiais e componentes [4]. Já na área de economia poderia se pensar no tempo decorrido entre a emissão do cartão de crédito e a 1ª vez que o cliente ficou inadimplente das despesas realizadas com o cartão [5]. Algumas variáveis que poderiam afetar o tempo até a inadimplência e que, portanto, deveriam ser investigadas seriam, idade, composição familiar, renda familiar, dentre outras. Sendo assim, não é difícil perceber que Análise de Sobrevivência é uma técnica com aplicação em áreas diversas, mas neste estudo foi focada no contexto de oncologia, tendo como objetivo geral identificar características da paciente, da doença e do tratamento que contribuem para a sobrevida de mulheres em seu 1º tratamento contra o câncer de mama. Os objetivos específicos a serem mencionados são:

- i) descrever as curvas da função de sobrevida e estimar o tempo mediano de sobrevivência, de acordo com características da paciente, da doença e do tratamento;
- ii) descrever as curvas das funções de sobrevivência e testar se são estatisticamente iguais ao se comparar estratos relativos a características da paciente, da doença e do tratamento.

2 Desenvolvimento do trabalho

2.1 Estudo dirigido

Na 1ª etapa do trabalho foi realizado um estudo dirigido sobre os seguintes tópicos de Análise de Sobrevida: Método de Kaplan-Meier para estimação da função de sobrevida global e por estratos, estimação do tempo mediano de sobrevida e Teste Log-Rank para Comparação de Funções de Sobrevida. Tais tópicos serão relatados brevemente nesta seção.

2.1.1 Definições básicas

Na Análise de Sobrevida, conforme já mencionado, o objetivo principal pode ser identificar características que influenciam o tempo decorrido entre o início da observação do objeto de interesse do estudo e a ocorrência de um evento denominado *falha* [1, 2, 3]. Na área de saúde a *falha* em geral é o óbito do paciente, mas pode ser também a calcificação de um osso após a fratura. Então o termo *falha* não deve ser necessariamente associado a um evento ruim, mas sim ao evento que se almeja investigar. No entanto, nem sempre é observado o tempo até a falha do objeto de estudo (paciente, equipamento, conta bancária, etc). Nestes casos, diz-se que ocorre o evento denominado *censura*. Para formalizar alguns conceitos de Análise de Sobrevida, utilizados ao longo da investigação, deve-se ter clareza sobre algumas definições [1, 2, 3], a saber:

- *T*: variável aleatória que denota o tempo decorrido entre o início do acompanhamento de um elemento/indivíduo na pesquisa até a ocorrência da *falha*.
- *falha*: evento de interesse no estudo
- *censura*: evento que indica a não observação do tempo até a falha.

As censuras podem ser classificadas como à esquerda, intervalar e à direita, sendo esta última a mais comum [1]. Na censura à direita há a perda da informação sobre o tempo

decorrido até falha, seja porque o indivíduo sob acompanhamento decidiu não participar mais do estudo, seja porque saiu do estudo devido a uma causa não relacionada com a falha ou mesmo porque o estudo se encerrou e a falha ainda não havia ocorrido. Entretanto, existem censuras relacionadas à falha como, por exemplo, quando do agravamento do estado de saúde de um paciente e a necessidade de transferência de hospital. Portanto, o primeiro hospital perde a informação do paciente que estava sob acompanhamento, mas o tempo de sua permanência no estudo não deve ser ignorado. Neste caso, técnicas mais complexas de Análise de Sobrevida são contempladas.

Nas pesquisas que envolvem Análise de Sobrevida também é usual os desenhos dos estudos considerarem as coortes abertas, que permitem a entrada de qualquer novo participante na investigação a qualquer momento dentro de uma janela temporal que delimita o início e o fim da pesquisa. A Figura 1 ilustra uma coorte aberta onde há 5 pacientes que falham e 5 pacientes que são censurados à direita. Observa-se então que, considerando a janela temporal da pesquisa de 2010 a 2019, apenas os indivíduos 1, 4 e 7 começaram a participar do estudo desde o seu início e os demais indivíduos entraram em momentos distintos. Percebe-se, por exemplo, que o indivíduo 2, que havia entrado no estudo em 2013 e falhado em 2017, contribui na pesquisa com o tempo de falha de 4 anos. Já o indivíduo 10, cuja entrada e saída do estudo (devido à censura) foram respectivamente em 2011 e meados de 2013, contribui com o tempo de 2,5 anos.




Figura 1: Estudo na Escala Cronológica

2.1.2 Método de Kaplan-Meier

Primeiramente seja definida a função de sobrevivência (ou de sobrevida) associada ao tempo t , por:

$$S(t) = P(T > t), t \in \mathbb{R} \quad (2.1)$$

Teoricamente a função de sobrevivência tem características como

$$S(0) = 1 \text{ e } \lim_{t \rightarrow \infty} S(t) = 0 \quad (2.2)$$




Figura 2: Curva Teórica da Função de Sobrevivência

No método de Kaplan-Meier as estimativas da função de sobrevivência se baseiam exclusivamente nos dados que foram observados ao longo do período da pesquisa com as estimativas da função de sobrevida sendo obtidas para determinados intervalos de tempo, definidos a partir das falhas observadas. No método, formalmente são considerados:

- $t_1 < t_2 < t_3 < \dots < t_k$: k tempos de falha distintos observados na investigação.
- d_j : N^0 de falhas ocorridas no tempo t_j .
- c_j : N^0 de censuras ocorridas no intervalo $[t_j, t_{j+1})$
- n_j : N^0 de indivíduos em risco de falha no tempo imediatamente anterior a t_j .

para todo $j = 1, \dots, k$.

No cenário apresentado na Figura 1, não é difícil identificar que existem $k = 5$ tempos de falha distintos (1, 2, 4, 5 e 8) e, sendo assim, podem ser obtidos os valores exibidos na Tabela 1.

Tabela 1: Números de indivíduos em risco, de falhas e de censuras, por tempo de falha

j	t_j	n_j	d_j	c_j
1	$t_1 = 1$	10	1	1
2	$t_2 = 2$	8	1	2
3	$t_3 = 4$	5	1	1
4	$t_4 = 5$	3	1	0
5	$t_5 = 8$	2	1	1

Para então se estimar a função de sobrevivência no tempo $t_1 = 1$, basta avaliar quantos indivíduos havia em risco e quantos sobreviveram a este tempo, ou seja:

$$P(T > 1) = \frac{n_1 - d_1}{n_1} = \frac{10 - 1}{10} \quad (2.3)$$

$$\hat{S}(1) = 0,900 \quad (2.4)$$

Para o tempo $t_2 = 2$, deve-se atentar que para sobreviver ao tempo 2, há que ter sobrevivido primeiramente ao tempo $t_1 = 1$ e não ter sido censurado no intervalo $[t_1, t_2) = [1, 2)$. Em termos de probabilidades, isso pode ser expresso por:

$$P(T > t_2) = P(T > t_1 \cap T > t_2) = P(T > t_2 \mid T > t_1) \cdot P(T > t_1) \quad (2.5)$$

mas,

$$P(T > t_2 \mid T > t_1) = \frac{n_2 - d_2}{n_2} \quad (2.6)$$

Assim,

$$P(T > 2) = P(T > 2 \mid T > 1) \dot{P}(T > 1) = \frac{8 - 1}{8} \cdot 0,900 = 0,787 \quad (2.7)$$

Portanto,

$$\hat{S}(2) = 0,787 \quad (2.8)$$

O processo se repete para os demais tempos de falha, podendo o estimador da função de sobrevida, via método de Kaplan-Meier, ser expresso por

$$\hat{S}(t) = \prod_{j|t_j \leq t} \frac{n_j - d_j}{n_j} \quad (2.9)$$

Com os dados exibidos anteriormente seriam obtidos os valores apresentados na Tabela 2 e a respectiva curva da função de sobrevivência teria o comportamento exibido na Figura 3. Observa-se claramente que a curva em formato escada (Figura 3) contém pontos de descontinuidade, diferentemente da teórica (Figura 2), mas caso o número de indivíduos

na pesquisa fosse maior, mais valores distintos de tempos de falha ocorreriam, suavizando a curva de sobrevida.

Tabela 2: Estimativas para a função de sobrevivência por tempo de falha

j	$t \in [t_j, t_{j+1})$	$\hat{S}(t)$
—	$[0, 1)$	1,000
1	$[1, 2)$	0,900
2	$[2, 4)$	0,787
3	$[4, 5)$	0,630
4	$[5, 8)$	0,420
5	$[8, \infty)$	0,210




Figura 3: Curva Estimada da Função de Sobrevivência

O método de Kaplan-Meier também permite que sejam obtidas estimativas para subgrupos de participantes da pesquisa. Em geral, consideram-se estratos das variáveis qualitativas contempladas na investigação. Assim, em um estudo que se investiga a sobrevida de pacientes com uma certa doença crônica, sendo a falha definida como o óbito do paciente, seria possível estimar as funções de sobrevivência, por exemplo, de acordo com os estratos da faixa etária do paciente (jovens/adultos/idosos), estágio da doença no momento do diagnóstico (inicial/intermediário/avançado) e tipo de tratamento (A/B), dentre outros. O procedimento metodológico seria o mesmo, mas considerando cada estrato separadamente. Em termos de representação gráfica, as curvas de cada estrato são usualmente exibidas em uma mesma figura. Por exemplo, caso os indivíduos 1, 2, 5, 7 e 9 tivessem sido submetidos ao tratamento A e os demais ao tratamento B, as curvas das funções de sobrevivência de cada tratamento estariam de acordo com o que é ilustrado na

Figura 4. O comportamento das curvas sugere que há maior risco de óbito para aqueles que se submetem ao tratamento B, uma vez que se identifica, dentre outros aspectos, que $\hat{S}(2)$ vale 1,00 e 0,533, respectivamente para os tratamentos A e B.




Figura 4: Curva estimada da função de sobrevivência por estratos - Kaplan-Meier

A interpretação gráfica das curvas de sobrevivência referentes aos estratos de uma variável, por ter um cunho pessoal e subjetivo, pode algumas vezes induzir a conclusão sobre diferenças das funções de sobrevida, que de fato não existem. Assim, há de se considerar um teste estatístico que averigüe a igualdade ou não nas sobrevidas associadas a cada um dos estratos. O teste Log-Rank viabiliza esta avaliação.

2.1.3 Teste Log-Rank

O teste Log-Rank, em sua essência, verifica se as frequências observadas de falhas nos r estratos ao longo dos tempos t_j ($j = 1, 2, \dots, k$) são estatisticamente iguais (ou não) as frequências esperadas de falhas, considerando que os estratos tenham funções de sobrevida idênticas. Assim, as hipóteses envolvidas no teste são:

$$\begin{aligned} H_0 : S_1(t) &= S_2(t) = \dots = S_r(t), \\ H_1 : \exists u, v \mid S_u(t) &\neq S_v(t) \end{aligned} \quad (2.10)$$

sendo r o número de estratos da variável em análise e $S_i(t)$ a função de sobrevivência do i -ésimo estrato ($i = 1, \dots, r$).

Para cada tempo de falha t_j é construída uma tabela com informações sobre o número de indivíduos em risco e de falhas em cada estrato, conforme exibido na Tabela 3.

Tabela 3: Números de indivíduos em risco e de falhas, por estrato e no tempo t_j

Estrato	Nº em risco	Nº de falhas
1	n_{1j}	d_{1j}
2	n_{2j}	d_{2j}
$\vdots$	$\vdots$	$\vdots$
r	n_{rj}	d_{rj}
Total	n_j	d_j

Assim, a proporção de falhas em cada estrato, no tempo t_j , é dada por:

$$\frac{d_{ij}}{n_{ij}}, \quad i = 1, \dots, k \quad j = 1, \dots, k \quad (2.11)$$

Nota-se que uma vez fixado o tempo t_j e dada a hipótese nula, as proporções de falha em cada estrato deveriam ser bem parecidas. Isso significaria que a ocorrência da falha não estaria associada aos estratos da variável investigada e, dessa forma, a proporção de falhas no tempo t_j poderia ser estimada diretamente por:

$$\frac{d_j}{n_j}, \quad j = 1, \dots, k \quad (2.12)$$

Uma vez obtida essa estimativa, esperar-se-ia que o número de falhas no estrato i ($i = 1, 2, \dots, r$) fosse:

$$e_{ij} = n_{ij} \cdot \frac{d_j}{n_j}, \quad j = 1, \dots, k \quad (2.13)$$

Portanto, o vetor de desvios no tempo t_j seria dado por:

$$\mathbf{w}_j = \begin{pmatrix} d_{1j} - e_{1j} \\ d_{2j} - e_{2j} \\ \vdots \\ d_{rj} - e_{rj} \end{pmatrix} \quad (2.14)$$

e o vetor de desvios ao longo de todos os k tempos de falha, dado por:

$$\mathbf{w} = \sum_{j=1}^k \mathbf{w}_j = \begin{pmatrix} \sum_{j=1}^k (d_{1j} - e_{1j}) \\ \sum_{j=1}^k (d_{2j} - e_{2j}) \\ \vdots \\ \sum_{j=1}^k (d_{rj} - e_{rj}) \end{pmatrix} \quad (2.15)$$

A estatística de teste a ser utilizada teria a seguinte expressão [3]:

$$\mathbf{w}^\top \mathbf{W}^{-1} \mathbf{w} \quad (2.16)$$

sendo $\mathbf{W} = \sum_j \mathbf{W}_j$, com $\mathbf{W}_j$ denotando a matriz variância-covariância (de dimensão $r \times r$) da quantidade de falhas dos estratos no tempo t_j . Além disso a estatística de teste, à medida que o tamanho da amostra de elementos no estudo aumenta, tende a ter uma distribuição χ^2 com $r - 1$ graus de liberdade [3]. Com base nessa distribuição é viável calcular o *p-valor* associado ao teste e inferir se a hipótese nula de igualdade das funções de sobrevivência será rejeitada ou não.

2.1.4 Tempo mediano de sobrevivência

O tempo mediano de sobrevida é uma medida usual para resumir o comportamento da função de sobrevivência. Ele é definido como sendo o valor de t para o qual $S(t) = 0,50$ [1]. No caso do método de Kaplan-Meier, por conta das descontinuidades da função de sobrevivência, ele é estimado como sendo o menor valor de t para o qual $\hat{S}(t) \leq 0,5$. Analisando a Figura 3, identifica-se que o tempo mediano de sobrevida é 5 anos.

2.1.5 Intervalos de confiança para valores da função de sobrevida

As estimativas pontuais fornecidas pelo método de Kaplan-Meier, em si, não contemplam a variabilidade deste estimador, tornando-se conveniente, também, a construção de intervalos de confiança para os valores da função de sobrevivência, uma vez que estes são conjuntos cuja probabilidade de conterem o parâmetro de interesse (sobrevida) é alta. Esta probabilidade é chamada nível de confiança.

Fixado o nível de confiança (comumente 95%), a variabilidade do estimador é refletida na amplitude dos intervalos obtidos; intervalos mais largos sugerem maior incerteza sobre o verdadeiro valor do parâmetro, ao passo que intervalos de menor amplitude não.

A fim de iniciar um processo para obtenção de uma expressão para a variância do estimador de Kaplan-Meier, e, conseqüentemente, uma fórmula para o cálculo dos intervalos de confiança das suas estimativas, o estimador será reescrito da seguinte forma:

$$\hat{S}(t) = \prod_{j|t_j \leq t} \hat{p}_j, \quad (2.17)$$

onde $\hat{p}_j = (n_j - d_j)/n_j$ representa a probabilidade estimada de um indivíduo sobreviver ao tempo t_j , dado que sobreviveu até o instante imediatamente anterior a este tempo.

Aplicando-se o logaritmo em (2.17), obtém-se

$$\log \hat{S}(t) = \sum_{j|t_j \leq t} \log \hat{p}_j. \quad (2.18)$$

E assumindo-se independência entre os $\hat{p}_j$:

$$\text{Var}(\log \hat{S}(t)) = \sum_{j|t_j \leq t} \text{Var}(\log \hat{p}_j). \quad (2.19)$$

Pode-se considerar que o número de indivíduos que sobrevivem além do tempo t_j , isto é, $n_j - d_j$, segue uma distribuição binomial com parâmetros n_j e p_j [6]. Assim, a variância desse número será dada por

$$\text{Var}(n_j - d_j) = n_j p_j (1 - p_j), \quad j = 1, \dots, k. \quad (2.20)$$

Como $\hat{p}_j = (n_j - d_j)/n_j$, segue que

$$\text{Var}(\hat{p}_j) = \frac{p_j(1 - p_j)}{n_j}, \quad (2.21)$$

Dada a impossibilidade de se obter expressões analíticas para $\text{Var}(\log \hat{p}_j)$, e considerando que $\hat{p}_j$ é o estimador de máxima verossimilhança para p_j [3], utiliza-se o método Delta [7] para se obter uma aproximação desta quantidade sob a hipótese de um tamanho amostral grande o suficiente:

$$\text{Var}(\log \hat{p}_j) \approx \left(\frac{1}{p_j} \right)^2 \text{Var}(\hat{p}_j) = \frac{(1 - p_j)}{p_j n_j} \quad (2.22)$$

Dai

$$\text{Var}(\log \hat{S}(t)) \approx \sum_{j|t_j \leq t} \frac{(1 - p_j)}{p_j n_j} \quad (2.23)$$

Utilizando novamente o método Delta (e o fato de $\hat{S}(t)$ ser um estimador de máxima verossimilhança) tem-se a aproximação abaixo:

$$\text{Var}(\log \hat{S}(t)) \approx \frac{1}{[\hat{S}(t)]^2} \text{Var}(\hat{S}(t)) \quad (2.24)$$

Logo,

$$\text{Var}(\hat{S}(t)) \approx [\hat{S}(t)]^2 \text{Var}(\log \hat{S}(t)) \quad (2.25)$$

Substituindo p_j por $\hat{p}_j$ em (2.25), têm-se

$$\widehat{\text{Var}}(\hat{S}(t)) = [\hat{S}(t)]^2 \sum_{j|t_j \leq t} \frac{d_j}{n_j(n_j - d_j)} \quad (2.26)$$

Tal equação é conhecida como fórmula de Greenwood [2]. A título de exemplo, a variância da estimativa de $S(1)$ foi estimada por meio dela em 0,009; consequentemente, o erro padrão em $\sqrt{0,009} = 0,0949$.

De posse de uma expressão para a variância do estimador, poder-se-à determinar o intervalo de nível aproximadamente $100(1 - \alpha)\%$ de confiança em torno de $\hat{S}(t)$ [6]

$$\hat{S}(t) \pm z_{\alpha/2} \sqrt{\widehat{\text{Var}}[\hat{S}(t)]}. \quad (2.27)$$

E tem-se o seguinte IC de 95% de confiança para $S(1)$:

$$0,9 \pm 1,96 \times \sqrt{0,009} \Rightarrow (0,7140; 1,0859). \quad (2.28)$$

Como pode ser percebido, a expressão conduziu a uma estimativa de sobrevivência maior do que 1, o que, no caso, é absurdo. Para lidar com este problema, uma proposta é obter um intervalo de confiança (através do método delta) para $\ln(-\ln S(t))$ e, posteriormente, um intervalo não-simétrico para $S(t)$ [3]:

$$\widehat{\text{Var}}[\ln(-\ln S(t))] = \frac{\sum_{j|t_j \leq t} \frac{d_j}{n_j(n_j - d_j)}}{\left[\sum_{j|t_j \leq t} \ln\left(\frac{n_j - d_j}{n_j}\right) \right]^2} = \frac{\sum_{j|t_j \leq t} \frac{d_j}{n_j(n_j - d_j)}}{[\ln(\hat{S}(t))]^2}. \quad (2.29)$$

O intervalo de $100 \times (1 - \alpha)\%$ de confiança simétrico para $\ln(-\ln S(t))$ fica expresso por:

$$\ln(-\ln \hat{S}(t)) \pm z_{\alpha/2} \times \sqrt{\widehat{\text{Var}}[\ln(-\ln \hat{S}(t))]} \quad (2.30)$$

Ou seja, os limites do intervalo serão:

$$l_{\text{inf}} = \ln(-\ln \hat{S}(t)) - z_{\alpha/2} \times \sqrt{\widehat{\text{Var}}[\ln(-\ln \hat{S}(t))]} \quad (2.31)$$

$$l_{\text{sup}} = \ln(-\ln \hat{S}(t)) + z_{\alpha/2} \times \sqrt{\widehat{\text{Var}}[\ln(-\ln \hat{S}(t))]} \quad (2.32)$$

Por fim, obtêm-se os limites do intervalo de $100 \times (1 - \alpha)\%$ de confiança não simétrico para $S(t)$:

$$l_{\text{inferior}} : \exp(-\exp(l_{\text{sup}})), \quad (2.33)$$

$$l_{\text{superior}} : \exp(-\exp(l_{\text{inf}})). \quad (2.34)$$

E o novo intervalo de 95% de confiança para $S(1)$ utilizando esta abordagem será (0,732; 1).

2.2 Revisão bibliográfica

No intuito de verificar o que já havia sido divulgado na literatura científica foi feita uma busca bibliográfica de trabalhos realizados no período de 2020 a 2025 sobre o tema “câncer de mama”. Sendo assim, utilizando-se as palavras chaves “câncer de mama”, “análise de sobrevivência - câncer de mama” e “prognósticos para câncer de mama” foram identificados estudos relevantes, onde alguns deles serão brevemente reportados aqui.

Um estudo publicado em 2021, investigou o perfil epidemiológico e a sobrevida de mulheres jovens diagnosticadas com câncer de mama entre janeiro de 2006 e dezembro de 2019 [8]. As participantes estavam inseridas no Registro Hospitalar de Câncer (RHC) do Hospital das Clínicas da Faculdade de Medicina de Ribeirão Preto da Universidade de São Paulo (HCFMRP-USP). A amostra foi composta por 327 mulheres, com idades entre 18 e 40 anos. Faleceram 28,7% das participantes. Dentre as 74 mulheres que foram a óbito em decorrência do câncer de mama (22,6% da amostra) a média de idade foi de 38,2 anos, sendo a maioria delas negra ou mulata, sedentária, com índice de massa corporal (IMC) acima do ideal e usuária de contraceptivos hormonais por mais de cinco anos; além disso,

todas elas foram diagnosticadas com câncer em estágio IV, com metástase à distância, e apresentavam receptores hormonais positivos. Ao nível de significância de 0,05, os testes Qui-Quadrado e/ou Exato de Fisher indicaram associação entre a ocorrência de óbito por câncer de mama e as variáveis tabagismo, ausência de cirurgia mamária e realização de tratamento quimioterápico. As funções de sobrevivência geral e estratificadas foram estimadas por meio do método de Kaplan-Meier. A análise indicou que a probabilidade de sobreviver por mais de cinco anos após o diagnóstico foi de 0,76, já a função de sobrevida em oito anos e sete meses foi estimada em 0,59. A visualização das curvas de sobrevivência estratificadas revelou que alguns grupos específicos apresentaram menor probabilidade de sobrevivência ao longo do tempo. Dentre eles: mulheres autodeclaradas negras ou mulatas, com idade entre 30 e 35 anos, com uso prolongado de contraceptivos hormonais ou que realizaram tratamento radioterápico.

Em 2014, uma análise realizada com 324 pacientes diagnosticadas com câncer de mama e atendidas no Ahmadu Bello University Teaching Hospital, localizado em Zaria, na Nigéria, investigou a sobrevida dessas mulheres [9]. A média de idade das participantes foi de 43,39 anos, com desvio padrão de 11,74 anos. Utilizando o método de Kaplan-Meier, estimou-se um tempo mediano de sobrevida de 10 meses. Ao nível de significância de 0,05, o teste de Log-rank indicou diferenças estatisticamente significativas na sobrevida entre os níveis dos estratos estágio do câncer, faixa etária e resultado do tratamento. Pacientes com idade entre 20 e 39 anos, diagnosticadas em estágio clínico IV ou que não apresentaram resposta favorável ao tratamento exibiram curvas de sobrevivência abaixo das observadas nos demais níveis de seus respectivos estratos, o que sugere um risco mais elevado de óbito por câncer entre aquelas que se encontravam em alguma dessas condições.

A análise de sobrevida também foi foco de uma pesquisa baseada em uma coorte histórica composta por 1.002 mulheres diagnosticadas com câncer de mama entre os anos de 2000 e 2002 no Hospital da Irmandade Nosso Senhor dos Passos, localizado no estado de Santa Catarina [10]. A proporção da amostra que veio a óbito foi 26,1%; já a que veio a óbito por causa do câncer de mama foi 23,45%. Estimada por meio do método de Kaplan Meier, a função de sobrevida avaliada em 5 anos foi de 0,76. A aplicação do modelo de riscos proporcionais de Cox aos dados revelou que os fatores independentes associados a um aumento no risco de morte por câncer de mama foram: idade inferior a 30 anos, analfabetismo e diagnóstico em estágios avançados (III e IV). Além disso, ao nível de significância de 0,05, o teste de Log-rank indicou diferenças estatisticamente significativas nas curvas de sobrevida de acordo com as variáveis escolaridade e raça/cor, sugerindo que a incidência do óbito por câncer de mama para cada nível destes estratos se dá de forma

distinta.

Com foco na região norte do Brasil, um levantamento publicado em 2022 analisou a sobrevida em cinco anos e os fatores prognósticos de 1.430 mulheres tratadas por câncer de mama no Hospital Ophir Loyola, localizado na cidade de Belém [11]. O estudo abrangeu o período de 2007 a 2013. A idade média ao diagnóstico foi de 53,01 anos. A maioria das pacientes era casada (54,3%), possuía baixa escolaridade (62,6%) e se autodeclarava não branca (90,5%). No momento do diagnóstico, 58,8% apresentavam comprometimento linfonodal, 80,8% não apresentavam metástases à distância e 51,1% estavam em estágio clínico avançado. Foram a óbito 20,5% das participantes do estudo. As funções de sobrevivência com e sem estratificação foram estimadas pelo método de Kaplan-Meier. Em relação aos aspectos sociodemográficos, a escolaridade mostrou-se fator relevante: mulheres com maior nível educacional apresentaram probabilidade de sobrevivência em cinco anos de 0,844, enquanto aquelas com baixa escolaridade registraram 0,734. Pacientes com menos de 30 anos apresentaram probabilidades de sobrevivência significativamente menores em comparação aos demais grupos etários. Além disso, a raça e o encaminhamento pelo sistema público de saúde estiveram associados a uma menor sobrevida. Em relação ao tipo de tratamento, a radioterapia e a hormonioterapia contribuíram positivamente, com funções de sobrevida em 5 anos iguais a 0,814 e 0,925, respectivamente, ao passo que a quimioterapia contribuiu menos, pois para este grupo, esta mesma função avaliada no mesmo tempo foi igual a 0,764.

Por fim, uma pesquisa transversal investigou a prevalência e os fatores associados ao diagnóstico de câncer de mama em estágio avançado entre 18.890 mulheres assistidas em hospital especializado da capital do Rio de Janeiro, Brasil, entre os anos 1999 e 2016 [12]. Utilizou-se regressão de Poisson com variância robusta para estimar razões de prevalência e os respectivos intervalos de 95% de confiança. Apresentaram maiores prevalências de diagnóstico de câncer em estágio avançado mulheres com idade entre 20-39 e 40-49 anos, de raça/cor da pele preta e parda, que viviam sem companheiro(a), procedentes de outros municípios do estado do Rio de Janeiro, que tiveram o Sistema Único de Saúde como origem do encaminhamento e que foram diagnosticadas nos sexênios 1999-2004 e 2005-2010. Em contrapartida, mulheres com idade entre 60-69 e 70-99 anos, que cursaram algum nível de escolaridade, com histórico familiar de câncer e que chegaram ao hospital com diagnóstico e sem tratamento apresentaram menores prevalências de diagnóstico em estágio avançado.

2.3 Acesso e análise preliminar dos dados

Foram utilizados os dados de todo o Brasil do Integrador RHC [13], referentes aos anos de 2010 a 2019. As seguintes restrições foram realizadas neste banco de dados:

1. Tipo de caso de câncer (TPCASO): analítico.
2. Localização do câncer (LOCTUDET): mama (CID C50).
3. Sexo: feminino.
4. Diagnóstico ou tratamento anterior (DIAGANT): sem diagnóstico e sem tratamento prévios.
5. Razão para o não tratamento no hospital (RZNTR): não se aplica.
6. Estado da doença ao final do primeiro tratamento (ESTDFIMT): óbito (falha) e demais códigos, exceto "não se aplica" e "sem informação".
7. Primeiro tratamento no hospital (PRITRATH): todos os códigos, exceto "não se aplica".
8. Tipo Histológico: mulheres cujo quinto (e último) dígito do tipo histológico (TIPOHIST) era 2 ou 3. Estes dígitos identificam neoplasias "in situ" e malignas primárias, respectivamente.
9. Consistência temporal: data da primeira consulta $\leq$ data do diagnóstico $\leq$ data do início do tratamento.
10. Data de óbito (DATAOBITO): todas as pacientes que foram a óbito devem possuir data de óbito registrada.
11. Raça/Cor (RACACOR): mulheres pretas, pardas e brancas.
12. Ocorrência de múltiplos tumores (MAISUMTU): todos os códigos, exceto "duvidoso".
13. Idade (IDADE): mulheres com idade maior ou igual a 20 anos.

Posteriormente uma análise preliminar descritiva dos dados foi efetuada no intuito de verificar a distribuição de frequências das categorias das variáveis qualitativas e também

o grau de preenchimento das variáveis no banco de dados. Dessa forma, devido ao satisfatório grau de preenchimento de informações foram selecionadas para serem contempladas no estudo as variáveis exibidas na Quadro 1. Além disso, tendo como base datas declaradas, foram criadas duas variáveis para quantificar os tempos decorridos entre a primeira consulta e o diagnóstico e entre o diagnóstico e o início do tratamento. Após todos esses procedimentos, para adotar a metodologia de Análise de Sobrevida, ficaram disponíveis 30.613 registros.

Quadro 1: Variáveis do banco de dados utilizadas no estudo

Variável	Descrição	Categorias originais	Categorias adotadas no trabalho
IDADE	Idade da paciente	≥ 20	$[20,40)$; $[40,60)$; ≥ 60
ESTCONJ	Estado conjugal atual	1: solteiro 2: casado 3: viúvo 4: separado judicialmente 5: união consensual 9: sem informação	1-5
INSTRUC	Escolaridade	1: nenhuma 2: fundamental incompleto 3: fundamental completo 4: nível médio 5: nível superior incompleto 6: nível superior completo 9: sem informação	1-6
LATERALI	Lateralidade do tumor	1: direita 2: esquerda 3: bilateral 8: não se aplica 9: sem informação	1-3
MAISUMTU	Ocorrência de mais um tumor primário	1: não 2: sim 3: duvidoso	1,2
ESTDFIMT	Estado da doença ao final do tratamento	1: remissão completa 2: remissão parcial 3: doença estável 4: doença em progressão 5: suporte terapêutico oncológico 6: óbito 8: não se aplica 9: sem informação	6: óbito 1-5: censura
PRITRATH	Primeiro tratamento recebido no hospital	1: nenhum 2: cirurgia 3: radioterapia 4: quimioterapia 5: hormonioterapia 6: transplante de medula óssea 7: imunoterapia 8: outras 9: sem informação	1-8
ESTADIAM	Estadiamento clínico do tumor	1; 1A; 1B 2; 2A; 2B 3A; 3B; 3C 4; 4A; 4B	$1 \longleftrightarrow 1$; 1A; 1B $2 \longleftrightarrow 2$; 2A; 2B $3 \longleftrightarrow 3A$; 3B; 3C $4 \longleftrightarrow 4$; 4A; 4B

2.4 Estimação das funções de sobrevivência e teste Log-Rank

O método de Kaplan-Meier foi adotado considerando as pacientes de forma geral e por estratos, de acordo com as seguintes características:

- i) da paciente: faixa etária, escolaridade e estado civil.
- ii) da doença: localização do tumor, lateralidade do tumor e estadiamento da doença quando do momento do diagnóstico.
- iii) do tratamento: tempo decorrido entre 1ª consulta e diagnóstico, tempo decorrido entre diagnóstico e início do tratamento, tratamento que contempla cirurgia, terapia de tratamento e tempo decorrido entre o diagnóstico e o início do tratamento

Considerou-se:

- *falha*: paciente ir a óbito ao final do 1º tratamento no hospital
- *T*: tempo decorrido entre o início do 1º tratamento no hospital até o óbito.

Todas as análises estatísticas foram efetuadas no software R [14] e considerou-se o nível de significância de 0,05 para a conclusão do teste Log-Rank.

3 Resultados

3.1 Análises estatísticas

Dentre as mulheres participantes do estudo, a média de idade foi 55,04 anos, sendo que, aproximadamente, metade das mulheres pertenciam a faixa etária de 40 a 60 anos (53,2%); eram em grande quantidade as mulheres brancas ou pardas (92,6%); a maior parte dos casos possuíam estadiamento clínico de nível II (37,94%). Já entre as 1431 mulheres que vieram a óbito (4,6%), a média de idade foi 55,91 anos; houve uma predominância de mulheres pardas (60%); os casos que possuíam estadiamento clínico de nível III ou IV somavam 80,4%; poucas possuíam mais de um tumor primário (7,2%).

Em relação aos tempos decorridos entre a primeira consulta e o diagnóstico e entre o diagnóstico e o início do tratamento, identificou-se que 33,8% e 72,9% das pacientes foram atendidas, respectivamente, conforme as leis federais nº 13.896/2019 e nº 12.732/2012. Além disso, 37,1% das pacientes que aguardaram mais de 60 dias (desde o momento do diagnóstico) para iniciar o tratamento, estavam com a doença no estadiamento 3 ou 4. Para as faixas de (0,30] e (30,60] dias, as prevalências foram, correspondentemente, de 40,5% e 43,7%. Analogamente, para o tempo decorrido entre a primeira consulta e o diagnóstico, os percentuais foram de 45,1% (faixa (0,30] dias), 34,2% (faixa (30,60]) e 28,4% (faixa > 60).

A estimativa de sobrevivência em 5 anos foi de 0,948 [IC95%: 0,946 ; 0,951]. As Figuras 6 a 17 exibem as funções de sobrevivência de forma geral e por estratos, com os respectivos resultados dos testes Log-Rank resultando em $p\text{-valor} < 0,05$. Pode ser observado que em nenhum dos cenários é possível obter o tempo mediano de sobrevivência, uma vez que $\hat{S}(t) > 0,50$ para todo valor de t considerado. Em relação as características das pacientes, estão sob maior risco de óbito as mais jovens, aquelas sem companheiros e as sem instrução, sendo que o risco diminui à medida que a escolaridade aumenta. No que diz respeito ao tratamento, fica evidente que a cirurgia e a radioterapia contribuem para a maior sobrevida das pacientes, ao passo que a quimioterapia não. Já em relação

as características da doença, foi identificado que quanto maior o estadiamento clínico da doença, menor a probabilidade de sobreviver e que a presença de múltiplos tumores ou a existência de tumores bilaterais geram impacto de redução na sobrevida da paciente. Por fim, em relação aos tempos decorridos para o diagnóstico ou tratamento, observou-se que menores tempos estão associados à maiores riscos de óbito.




Figura 5: Curva de sobrevivência para as pacientes de forma geral




Figura 6: Curva de sobrevivência por estado civil




Figura 7: Curva de sobrevivência por faixa etária




Figura 8: Curva de sobrevivência por escolaridade




Figura 9: Curva de sobrevivência por Raça/Cor




Figura 10: Curva de sobrevivência por estadiamento clínico do tumor




Figura 11: Curva de sobrevivência por lateralidade do tumor




Figura 12: Curva de sobrevivência por múltiplos tumores




Figura 13: Curvas de sobrevivência por tempo decorrido entre a 1ª consulta e o diagnóstico




Figura 14: Curva de sobrevivência por tempo decorrido entre o diagnóstico e o início do tratamento




Figura 15: Curvas de sobrevivência de acordo se o tratamento contempla cirurgia




Figura 16: Curvas de sobrevivência de acordo se o tratamento contempla radioterapia




Figura 17: Curvas de sobrevivência de acordo se o tratamento contempla quimioterapia

3.2 Divulgação dos resultados

Conceitos teóricos e resultados parciais das análises estatísticas foram divulgados nos seguintes meios:

- **Eventos Científicos**

1. **SIMMA 2025** – setembro de 2025 – Universidade Federal Fluminense (UFF), sede Volta Redonda (RJ).
 - Título do trabalho: *Impacto das características da doença na sobrevivência das pacientes com câncer de mama.*
 - Modalidade de apresentação: pôster.
2. **XVII MGEST** – outubro de 2025 – Universidade Federal de Lavras (UFLA).
 - Título do trabalho: *Influência das características sociodemográficas das pacientes em tratamento contra câncer de mama na função de sobrevivência.*
 - Modalidade de apresentação: pôster.
3. **14^a SEMEST** – outubro de 2025 – Universidade Federal Fluminense (UFF).
 - Título do trabalho: *Impacto das características da doença na sobrevivência das pacientes com câncer de mama.*
 - Modalidade de apresentação: pôster.

4. **Seminários de Iniciação Científica do IME** – dezembro de 2025 – Universidade Federal Fluminense (UFF).

- Título do trabalho: *Análise de Sobrevivência de Mulheres com Câncer de Mama Via Estimador de Kaplan-Meier e Teste Log-Rank*.
- Modalidade de apresentação: Oral

• **Publicações Científicas**

1. **Caderno de Estatística do Departamento de Estatística da Universidade Federal Fluminense (UFF)** – dezembro de 2025, volume 1, número 2.

- Título do trabalho: *Noções Iniciais de Análise de Sobrevivência e o Método de Kaplan-Meier*.
- Modalidade: artigo.
- Link: <https://est.uff.br/cadernos-de-estatistica/>

2. **Anais do Evento 14^a Semana da Estatística da Universidade Federal Fluminense (UFF) - outubro de 2025**

- Título do trabalho: *Impacto das características da doença na sobrevivência das pacientes com câncer de mama*.
- Modalidade: resumo.
- Link: <https://semest.uff.br/>

Além disso, foi desenvolvido e hospedado na plataforma *shinyapps.io* um painel interativo para visualização das curvas de Kaplan-Meier (gerais e estratificadas), bem como para a realização dos testes Log-Rank e análises descritivas. O aplicativo pode ser acessado em: <https://rtfooh-pedro-dutra.shinyapps.io/DashSurvivalBoard/>.

Por fim, todo o material produzido (e, portanto, discriminado neste relatório) encontra-se, de maneira integral e organizada, em um repositório no GitHub (site público) do aluno bolsista. O repositório encontra-se disponível em <https://github.com/FrazaPe/IC2025>.

4 Conclusão

De modo geral, as curvas estimadas da função de sobrevivência (Figuras 5 a 17) apresentaram valores iguais ou superiores a 0,9 ao longo de todo o período analisado, com exceção daquelas referentes às pacientes diagnosticadas em estadiamento clínico de nível IV (Figura 10) e às pacientes que não realizaram cirurgia (Figura 15). Este resultado indica que, no período considerado, a sobrevivência das mulheres em seu primeiro tratamento contra câncer de mama foi relativamente elevada.

Cabe destacar que algumas variáveis apresentaram estratos com curvas de sobrevivência visualmente próximas (Figuras 12, 13, 14 e 17). Ainda assim, os testes de Log-Rank indicaram diferenças estatisticamente significativas. Tal fato deve-se à sensibilidade do teste ao tamanho amostral, que neste estudo é muito elevado (30.613).

O fato do grupo etário das mulheres mais jovens ter apresentado menores valores da função de sobrevivência quando comparadas aos demais grupos etários (Figura 7) reforça a importância de políticas públicas voltadas ao diagnóstico precoce do câncer de mama em mulheres jovens, considerando que, atualmente, os programas governamentais de diagnóstico priorizam mulheres a partir dos 50 anos de idade.

A realização da quimioterapia aumentar o risco de óbito (Figura 17) pode ser interpretado da seguinte forma: em geral, pacientes com quadros clínicos mais graves são recomendados a este tipo de tratamento, o que justifica a menor sobrevivência neste grupo.

A única justificativa plausível identificada para o comportamento de maiores tempos decorridos até o diagnóstico ou tratamento estarem associados à maiores chances de sobreviver (Figuras 13 e 14), baseia-se no ocorrido que houve menor prevalência de pacientes no estágio 3 ou 4 entre as mulheres que aguardaram mais de 60 dias, comparativamente as demais faixas de tempo.

Foram encontradas dificuldades relacionadas à presença de inconsistências e à ausência de informações em algumas variáveis de interesse do banco de dados. Por exemplo, havia

poucas mulheres indígenas e pardas, isto reduz a precisão das estimativas de Kaplan-Meier nestes estratos. Esta limitação dentre outras justificam a realização das restrições nos dados, detalhadas na seção 2.3.

O projeto cumpriu seus objetivos ao identificar fatores que contribuem para a sobrevivência das mulheres e foi possível traçar um perfil associado a um melhor prognóstico: presença de companheiro, idade entre 40 e 60 anos, ensino superior completo, raça branca, estadiamento menor do que 3, ausência de tumores múltiplos ou bilaterais.

A pesquisa proposta foi realizada integralmente pelo aluno vinculado ao projeto, com êxito e em conformidade com o cronograma previamente estabelecido.

Referências

- 1 CARVALHO, M. S. et al. *Análise de Sobrevivência: Teoria e Aplicações em Saúde*. 2. ed. revista e ampliada. Rio de Janeiro: Fiocruz, 2011.
- 2 COLOSIMO, E. A.; GIOLO, S. *Análise de Sobrevivência Aplicada*. São Paulo: Blucher, 2006.
- 3 KALBFLEISCH, J. D.; PRENTICE, R. L. *The Statistical Analysis of Failure Time Data*. 2. ed. Hoboken: John Wiley & Sons, 2002.
- 4 MEEKER, W. Q.; ESCOBAR, L. A.; PASCUAL, F. G. *Statistical Methods for Reliability Data*. Hoboken: Wiley, 2021.
- 5 LANCASTER, J. J. *The Econometric Analysis of Transition Data*. Cambridge: Cambridge University Press, 1990.
- 6 COLLETT, D. *Modelling Survival Data in Medical Research*. 4. ed. Boca Raton: CRC Press, 2023.
- 7 CASELLA, G.; BERGER, R. L. *Statistical Inference*. 2. ed. Pacific Grove: Duxbury, 2002.
- 8 NUNES, L. C. *Análise do perfil epidemiológico e da sobrevida de mulheres jovens com câncer de mama*. 2021. Dissertação (Mestrado) — Universidade de São Paulo, Ribeirão Preto, 2021. Disponível em: <<https://www.teses.usp.br/teses/disponiveis/22/22133/tde-15122021-095231/>>.
- 9 USMAN, M.; DIKKO, H. G.; BALA, S.; GULUMBE, S. U. An application of Kaplan-Meier survival analysis using breast cancer data. *Sub-Saharan African Journal of Medicine*, v. 1, n. 3, p. 132–137, 2014. DOI: 10.4103/2384-5147.138940.
- 10 SCHNEIDER, I. J. C.; D'ORSI, E. Sobrevida em cinco anos e fatores prognósticos em mulheres com câncer de mama em Santa Catarina, Brasil. *Cadernos de Saúde Pública*, v. 25, n. 6, p. 1285–1296, 2009. DOI: 10.1590/S0102-311X2009000600011.
- 11 SANTOS, T. B. et al. Prevalência e fatores associados ao diagnóstico de câncer de mama em estágio avançado. *Ciência & Saúde Coletiva*, v. 27, n. 2, p. 471–482, 2022. DOI: 10.1590/1413-81232022272.36462020.
- 12 CRUZ, S. J. V. et al. Five-year survival rate and prognostic factors in women with breast cancer treated at a reference hospital in the Brazilian Amazon. *PLOS ONE*, v. 17, n. 11, p. 1–11, 2022. DOI: 10.1371/journal.pone.0277194.
- 13 INSTITUTO NACIONAL DE CÂNCER (INCA). Integrador RHC. Disponível em: <<https://irhc.inca.gov.br/RHCNet/visualizaTabNetExterno.action>>. Acesso em: 14 out. 2024.

- 14 R CORE TEAM. *R: A Language and Environment for Statistical Computing*. Vienna: R Foundation for Statistical Computing, 2014. Disponível em: <<http://www.R-project.org/>>.